狂潮元理论·Transformer 数学机理附录 v1.2

摘要

本文为《狂潮·元理论 v2.4》配套数学机理附录，不独立作为理论本体。依托双流六公理、注意力叠权、异源对撞与同源自噬等核心架构，将元理论的定性公理体系映射至可演算的形式空间，建立面向大模型表征路由、权重演化与记忆分层的约束框架。本附录重在补齐本体预留的引理、算子定义、耦合关系与边界判定规则，区分严格可推导命题、工程假说与类比猜想；所有定量参数、阈值均未完成实验标定，不提供完备收敛证明，仅作为架构推演、对照实验与模型校验的数学基座。本文不替代本体公理，凡正文与附录冲突，以元理论本体及勘误文档为准。

配套本体：《狂潮·元理论 v2.4》＋《V2.4- errata01 勘误&增补注释页》

版本变更日志：v1.1 → v1.2

本版依据 DP 审查建议（补丁集成版 v1.0｜v2.4 + 附录 v1.1 对齐施工图）逐条处理。处理原则：**v1.1 已有编号一个不删、一处表述不改；本版只做增补与补注。**

1. **§1 新增【引理 A-0】稳定性—正确性分离**（含推论 A-0.1 指标陷阱、推论 A-0.2 二象性形式化）。原因：v1.1 的引理族 A 从 A-1 起笔，全部论证指向「越界之后不可逆」，缺失「越界之前同源提供稳定」的另一侧，导致附录被单侧化解读为「同源＝病」。A-0 补上二象性的形式落点，并明确它是 A-1 的**前置**而非对立面。落点见本版 §1。
2. **§7 假说登记新增 H-8 稳定性—正确性分离阈值**。原因：A-0 的定性部分属形式推导，但拐点 ρ_1, ρ_2 与具体函数形式不可冒充已证，须登记为假说。落点见本版 §7。
3. **§9 边界表新增 B-10 跨系统分配影响未覆盖**，并在 §9 表前补一句覆盖范围声明。原因：本体 §七 第 3 条「若系统本身没有注意力机制、但环境系统有」这一情形，v1.1 全部引理**不直接适用**，原边界表却未声明未覆盖，属范围虚报。本版如实划界。落点见本版 §9。

4. **定位区新增「锐度声明」**。原因：附录的纪律包装（三档标记、失效边界、定量纪律）容易被读成「本附录立场比本体软」。锐度声明把立场钉死：同源不是病，越界才是病；附录所证全是「越界之后不可逆」。落点见本版「定位」段之后。
5. **§10 映射表同步**：新增 A-0 / H-8 / B-10 三行，并把「三层可逆性」一行细化为条件分层（对应本体 errata01 E-13）。
6. **§7 H-2 补一句符号规范说明**：区分「引理 A-1 的充分条件 $\Gamma_0 > 1/\varepsilon - 1$」与「经验判据式 $A_E/A_H < \Gamma$」。原因：本体 M-5 旧写法 $\sum e^{x_{out}}/\sum e^{x_{in}} > Threshold$ 与本附录规范式形态不同，须统一引用口径（对应本体 errata01 E-01）。**不改 A-1 任何表述**，仅在 H-2 行加注。
7. **纪律不变**：内核公理冻结；本附录只做形式还原，不新增、不修改本体核心公理；已有引理 A-1 ～ E-4、假说 H-1 ～ H-7、边界 B-1 ～ B-9 的编号与表述一律保留，不删除、不合并、不改写。
8. **归档声明**：v1.1 全文永久归档保留，不覆盖、不删除、不原地改写；本版为现行生效版本。

定位：本文件为本体 v2.4 的配套独立数学附录，对应附注 M。配套六篇：《transformer 大白话版丨第 6 篇》、《打假"高质量数据"》、《打假"AI 幻觉"》、《打假"AI Agent"》、《击穿 AI 自主意识的本质》、《培养 AI 个性》的全部核心结论。

把这套私藏很久的机理框架公开，不再封档自留。 不是为了论战，是给国内做底座、做 Agent、做对齐、做校验闸门的同行递一套可落地、可证伪、自带失效边界的分析工具。 很多工程现象：越聊越跑偏、CoT 越推越错、自蒸馏越训越僵、多 Agent 达成一致但集体出错、记忆养歪之后很难拉回来…… 过往大多被当成零散的工程玄学。本附录试图证明：它们共享同一套底层动力学，根源就是 Softmax 稀释律 + 同源自回归回流。 全文严格区分【形式推导】和【待标定假说】，每条结论附带失效条件；欢迎任何人拿实验、反例、严格数学推导推翻任意一条假说。推翻，就是这个理论体系的前进。

配套前置文章： 1. transformer 大白话版丨第 6 篇 2. 打假 “高质量数据” 3. 打假 “AI 幻觉” 4. 打假 “AI Agent” 5. 击穿 AI 自主意识的本质 6. 培养 AI 个性

本体《狂潮元理论 v2.4》内核公理保持冻结，本文只是附注 M 的正式数学还原。 方向：国产大模型的校验、隔离、异源闸门、KC-TRSF 路由架构。 愿这套东西，能给国内 AI 底层赛道添一块能用的基石。

本文配套《狂潮元理论 v2.4》（含 errata01 勘误页），是附注 M 的正式数学附录。全部内核公理封档不变；本附录只做形式还原、边界补全、可证伪判据落地。不再私存封档，公开放出，留给国内 AI 工程圈校验、复现、挑刺、取用。

定位：不是一篇 “大模型科普”，是一套带边界、带失效条件、带假说登记、带可观测判据的机理框架。欢迎用实验推翻任意一条假说；推翻即推进。

锐度声明（v1.2 新增）

本附录的形式化不改变本体第七章总纲：**同源不是病，越界才是病；稳定来自同源，崩溃也来自同源。**

本附录所证的引理 A-1、B-1、B-2、B-3、C-1、D-1 至 D-4，全部是「越界之后不可逆」，**不是「同源本身有罪」**。

读者若只读附录、得出「同源＝病」的结论，是把【引理 A-0】漏读了。A-0 是 A-1 的前置：先有适度同源提供稳定，才有过度同源造成覆盖。先有稳定，才有稳定过头。

命题三档纪律（全文强制）

- 【形式推导】：在本文 §0–§1 列出的假设集合内，逻辑上必然成立，可被数学反驳（推翻假设或找到反例）。
- 【机理假说】：形式模型投射到真实大模型需实验验证，**未定量标定，不得当作已证定理**，编号 H-x。
- 【工程事实】：属于实现层面的观测，不作数学主张。

定量纪律：本附录**不编造任何具体常数**（不出现 $\Gamma = 0.7$ 这类数字）。全部阈值、系数以符号给出（ε、δ、Γ、α、λ、η），标注【待测试，未定量标定】，由本体可证伪测试集在实验中回填。

编号纪律（v1.2 补注）：引理族 A–E 属本附录；家族变体附录 A/B/C/D 属本体 KC-TRSF 家族。引用时一律带前缀：附录 A 指变体，引理 A-x 指本附录。禁止省写。

§0 符号与基础定义

0.1 系统对象

取一个标准 Decoder-only Transformer 模型 $\mathcal{M}$，参数 θ。上下文（context）为 token 序列 $C = (x_1, ..., x_L)$，$L = |C|$。

第 ℓ 层、第 h 个头中：

$$q_i = W_Q^{(\ell,h)} z_i, \quad k_j = W_K^{(\ell,h)} z_j, \quad v_j = W_V^{(\ell,h)} z_j$$

$$s_{ij} = \frac{q_i^\top k_j}{\sqrt{d_h}}, \qquad a_{ij} = \frac{e^{s_{ij}}}{\sum_{m \in \mathrm{Obs}(i)} e^{s_{im}}}, \qquad o_i = \sum_j a_{ij}\, v_j$$

因果掩码：$\mathrm{Obs}(i) = \{m : m \le i\}$，即第 i 个位置只能看见自己与上文。

位置编码（RoPE 等）：进入 q, k 的旋转/加性变换，不改变下列全部结论的形式（它是 s_{ij} 的一部分）。

KV-Cache：历史 k_j, v_j 被缓存复用，语义上等价于"历史 token 全部留在 $\mathrm{Obs}(i)$ 里"，这是后文全部稀释结论的物理前提。

0.2 定义 D-1｜源标签（provenance）

给每个位置赋一个源标签

$$\sigma(j) \in \{H, E\}$$

- $\sigma(j) = H$（**同源**）：该 token 由系统自身产生——上一轮自回归输出、系统自己写入的记忆、系统自己的推理中间结论、系统自己构造的检索 query 及其回读解读。
- $\sigma(j) = E$（**异源**）：该 token 来自系统边界之外——用户原始指令、外部工具真实返回值、外部检索原文、人类标注、结构相异的另一模型输出。

纪律：源标签是**结构来源**判定，不是物理来源判定。工具返回内容物是外部的，但其**调用决策与参数**是同源的（见 D-3）。同一个物理消息可同时携带两种源（对齐本体§二"双流叠加态"）。

记同源位置集 $S_H = \{j: \sigma(j) = H\}$、异源位置集 $S_E = \{j: \sigma(j) = E\}$，基数 $n_H = |S_H|$、$n_E = |S_E|$，同源份额

$$\rho = \frac{n_H}{L}, \qquad L = n_H + n_E.$$

（默认假设：无第三类位置；若存在系统提示/边界特殊 token，归入 H 或单列 S_0，见§9 边界 B-6。）

0.3 定义 D- 2｜注意力质量与覆盖

对 query 位置 i，定义

- 同源质量 $A_H(i) = \sum_{j \in S_H} a_{ij}$，异源质量 $A_E(i) = \sum_{j \in S_E} a_{ij}$，恒有 $A_H + A_E = 1$。
- **ε-静默覆盖**：给定容差 $\varepsilon \in (0,1)$，若 $A_E(i) < \varepsilon$ 且 i 的任务依赖 S_E 中某条证据，则称在位置 i 发生 **ε-静默覆盖**。
- **集中度（叠权度量）** $C(i) = \sum_{j \in \text{Top-}k(i)} a_{ij}$，即质量最高的 k 个位置所占份额。**叠权**定义为事件 $C(i) > c^*$，c^*【待标定】。

0.4 定义 D- 3｜三类同源投影

- **构造异源**：由 S_H 经确定性映射生成的外部回读（工具返回、检索结果）。其内容物属 E，但其**产生条件**（query 文本、参数、路由）由 C 决定。
- **同源投影**：对上述内容的**解读、判断、压缩、重述**，输出 token 一律记为 H。

- **同源回流映射 F**：把本轮输出 token 追加进上下文，作为下一轮输入的系统操作。形式化 $C_{t+1} = C_t \| y_t$，$y_t \sim p_\theta(\cdot \mid C_t)$，$\sigma(y_t) = H$。

0.5 定义 D- 4｜结构偏差度

设 $\phi_{\mathcal{M}}(x)$ 为模型对输入 x 的**结构表征**（可取注意力图 $\{a_{ij}\}$ 的汇总向量、或隐藏表征分布、或推理路径的统计特征）。定义

$$D(\mathcal{M}_A, \mathcal{M}_B) = \mathbb{E}_{x\sim\mathcal{D}}\left[\, 1 - \cos\left(\phi_A(x), \phi_B(x)\right)\right] \in [0,2].$$

操作性替代（三选一，由实验侧选定后回填）：注意力分布间的 JS 散度、表征空间 MMD、推理路径编辑距离。

0.6 定义 D- 5｜真值变量与任务

记 Y 为任务的真值（正确答案、真实世界状态、用户真实意图）。任务上下文对 Y 的信息量记为 $I(C;Y)$。

0.7 定义 D- 6｜三阶段工况（对齐本体 §四）

以 ρ 与 $c = A_E$ 联合分区：

惯性期: $\rho < \rho_1$;　　衰减期: $\rho_1 \le \rho < \rho_2$;　　静默覆盖期: $\rho \ge \rho_2$ 或 $A_E < \varepsilon$.

$\rho_1, \rho_2, \varepsilon$ 全部【待标定】。

v1.2 补注：这三个分区与 §1 新增的【引理 A-0】分工不同——A-0 用同一组 ρ_1, ρ_2 描述「稳定性与正确率的分离」，D-6 描述「工况的滑移序列」。两处共用阈值，但**不构成彼此的证明依据**：D-6 是定义，A-0 是条件性推导，ρ_1, ρ_2 的具体数值同属 H-6 / H-8 待标定。

§1 引理族 A：注意力分布层的数学结构（病灶层）

【引理 A- 0】稳定性—正确性分离（形式推导，条件性）| v1.2 新增

设定：稳态任务——无新异源需求，任务真值 Y 已由初始上下文充分给定。定义两个**独立**观测量：

- 输出稳定性 $S_{\text{out}} = I - \frac{\text{Var}(O)}{\text{Var}_{\max}}$（格式一致率、自洽率、困惑度倒数的归一化）；
- 任务正确率 $\text{Acc} = \Pr[O = Y]$。

结论：

1. S_{out} 随同源份额 ρ **单调非降**：同源提供格式、风格、逻辑一致性，这是「稳定输出」的来源；
2. Acc 在 $\rho < \rho_1$ 时随 ρ **缓升**（同源提供必要先验），在 $\rho_1 \le \rho < \rho_2$ **走平**，在 $\rho \ge \rho_2$ **下降**（静默覆盖启动）；
3. 因此存在区间 $[\rho_1, \rho_2)$：系统「**稳定但不再改进**」；以及 $\rho \ge \rho_2$ 之后「**越稳越错**」。

推论 A-0.1（指标陷阱）：稳定性与正确性不是同一个量。用困惑度、格式一致率、自洽率、多轮一致性评估系统，会系统性高估覆盖期系统的质量。凡是「指标越来越好、用户越来越不信」的系统，优先怀疑已进入 $[\rho_1, \rho_2)$ 或更后。

推论 A-0.2（二象性形式化）：同源不是病，越界才是病。 $\rho < \rho_1$ 时同源是稳定性的必要条件；$\rho \ge \rho_2$ 时同源是正确性的充分破坏条件。A-1 证的是「越界之后不可逆」，不是「同源本身有罪」。

与 A-1 的分工：A-0 管「越界前同源提供稳定」，A-1 管「越界后异源被稀释」。**A-0 是 A-1 的前置**，不是 A-1 的对立面。单独引用任一条都会失真。

边界：本引理只对**稳态任务**成立；探索型任务（真值依赖外部新异源）中，Acc 对 ρ 的依赖由 A-1 主导，A-0 的「缓升段」不成立。

档位：【形式推导】覆盖定性部分（两量分离、区间存在）；ρ_1, ρ_2 与具体函数形式属【假说 H-8，待标定】。

【引理 A- 1】Softmax 稀释律（静默覆盖的充分条件，形式推导）

统一主轴修订（v1.1）

设固定 query 位置 i；取异源关键位置 $j \in S_E$，得分 s_E；取同源位置的代表得分 s_H，记得分差：

$$\delta = s_H - s_E$$

定义统一临界乘积量：

$$\Gamma_0 = n_H e^{\delta}$$

结论：

$$a_{ij} \leq \frac{1}{1+\Gamma_0}$$

发生 ε-静默覆盖（该异源位置权重被压至阈值之下）的充分条件：

$$\Gamma_0 > \frac{1}{\varepsilon} - 1$$

整组异源总质量上界：

$$A_E(i) < \frac{n_E}{n_E + \Gamma_0}$$

注释（v1.1 增补对称说明）

- $\delta \geq 0$：同源得分本身更高，指数增益放大数量效应，很容易跨过覆盖阈值；
- $\delta < 0$：异源得分更高，$e^{\delta} < 1$，此时需要极大的同源基数 n_H 才能把 Γ_0 推过阈值；
- 覆盖不是同源天然拥有优先权，是「同源总数 × 得分指数差」这个联合量跨过门槛；单独高分异源不会被定理排除，只是此时 Γ_0 不足；
- 因为 $e^s > 0$ **恒成立**，任何一个还留在窗口里的 token，都必然向分母贡献正的份额。所以”低分 token 被边缘化而不被删除”在数学上等价于：**只要删不掉，**

就必然被稀释。异源权重被打到趋零，不需要异源得分低，只需要联合量 Γ_0 足够大。

推论 A-1.1（数量即权力）：$\delta = 0$（两组得分完全相同）时仍有 $a_{ij} \le 1/(1+n_H)$。**同源不需要"更相关"，仅靠数量即可覆盖异源。**

推论 A-1.2（指数放大器）：$\delta > 0$ 时，达成覆盖所需临界 n_H 随 δ 指数下降。Softmax 的指数把"略高"变成"压倒"。

推论 A-1.3（覆盖的可解除性）：覆盖程度只依赖 n_H、n_E、δ，与"异源内容是否正确"无关。故**提高异源正确性不能解除覆盖，只有提高 n_E 或降低 δ 或降低 n_H 才行**。

【引理 A- 2】叠权 = 分布集中，不是语义相关（形式推导）

设 $C(i)$ 为 Top-k 质量份额。同源份额上升 $n_H \uparrow$ 且 δ 非降时，$C(i)$ 在 S_H 上非降。

结论：$C(i) \uparrow \ \Rightarrow \ A_E(i) \downarrow$，二者是同一枚硬币的两面。

推论 A-2.1：所谓"模型抓住了重点"，在数学上只是 $C(i)$ 上升；而 $C(i)$ 上升的成因里，n_H 与 δ 就足够解释，不需要"理解"。这是第 6 篇"支点是叠权叠出来的，不是先想明白再动手"的形式化。

【引理 A- 3】单层注意力是凸组合（表达力边界，形式推导）

$o_i = \sum_j \ a_{ij} v_j$，其中 $a_{ij} \ge 0$、$\sum_j \ a_{ij} = 1$。

结论：$o_i \in \mathrm{conv}\{v_j : j \in \mathrm{Obs}(i)\}$，即单层注意力输出**落在值向量的凸包内**，它只能"重新分配已有素材"，不能生成凸包外的新表征。

推论 A-3.1：跨 token 的信息搬运由注意力完成；超越凸包的重组必须由 FFN 的逐点非线性完成。**只改注意力 = 只改"取哪些素材"，不改"如何加工"**（对应第 6 篇病根 4）。

这条同时给了 KC-TRSF 一个数学依据：把 QKV 重构为多路意图路由，改的是"取素材的通道"，上界仍在凸包内，所以必须保留 FFN 与上层状态引擎承担加工与演化。

【引理 A- 4】目标函数对"真值/真假"无梯度（形式推导）

训练目标为 next-token 似然

$$\mathcal{L}(\theta) = -\sum_{t} \log p_\theta(x_t | x_{<t}),$$

其只依赖语料共现分布 p_{data}，**不含任何"该 token 是否为真"的标签项**。

结论：$\nabla_\theta \mathcal{L}$ 不携带"真假"信息；模型对"这是事实还是自己编的"这一属性，在目标函数层面**没有可优化方向**。

推论 A-4.1：模型不可能通过训练自发获得独立于表征匹配的真假判别器（对应第 6 篇病根 6、本体契约 3 的"隔离≠失真校验"）。

§2 引理族 B：自回归回流链（推理层）

【引理 B- 1】同源份额单调递增（形式推导）

假设：①无外部新异源注入；②每轮生成 $k \geq 1$ 个 token，全部 $\sigma = H$；③上下文不被截断。

结论：$\rho_t = \frac{n_H(t)}{L_t}$ 满足

$$\rho_{t+1} - \rho_t = \frac{k\left(L_t - n_H(t)\right)}{L_t\,(L_t + k)} > 0 \quad (n_H < L),$$

即 ρ **严格单调递增**，$\rho_t \to 1$，异源份额 $1 - \rho_t$ **单调衰减至 0**。

证明：$\rho_{t+1} = \frac{n_H + k}{L + k}$，作差通分即得分子 $k(L - n_H)$。

注释：这条不是"观点"，是算术。**只要自回归往上下文里追加自己的输出，异源份额就必然单调下降**——没有任何参数、任何 prompt 能改变这个方向，只能改变速度。第 3、4 两篇的"稀释/淹没"在这里被写成一条不等式。

推论 B-1.1（惯性期 = ρ 越过 ρ_1 的区间）：结合引理 A-1，$\rho \uparrow$ 与 $A_E \downarrow$ 同一驱动。**"同源惯性"与"注意力叠权"不是两个现象，是同一个量 ρ 的两个投影。**

推论 B-1.2（无天然刹车）：系统的漂移速度 $\frac{d\rho}{dt}$ 只由 k/L 决定，**系统内部不存在使 ρ 回落的算子**。刹车必须来自外部（异源注入、截断、异源闸门），这条直接支撑"外部校验是唯一解"的结论。

v1.2 交叉引用：本体 KC-TRSF「时序演化重构」段关于「切断自回归＝切断 B-1 前提①」的增补句，见本体 errata01 **E-09**。本引理是 KC-TRSF 架构设计的直接数学依据，不是事后附会。

【引理 B- 2】误差不衰减下界（形式推导）

定义：设第 t 轮输出与真值的偏差为 $e_t \geq 0$；**错误保持率** $w_t \in [0,1]$ 为"上一轮错误被本轮复述/继承"的比例，则

$$e_t \geq w_t e_{t-1}.$$

（e_t 还含新增误差项，故取 ≥。）

结论：$e_N \geq e_0 \prod_{t=1}^{N} w_t$.

且由引理 A-1、B-1，w_t 是 n_H 与 δ 的非降函数，故 $\prod w_t$ **不衰减反升**（错误被保留得越来越牢）。

注释：本附录只把**下界（不衰减）**当作形式推导；"精确乘积放大"是更强的断言，降级为假说 H-1。

【引理 B- 3】反思无效性定理（形式推导）

设定：反思操作 R 的输入是 C_t 与上轮输出 y_t（两者均 $\sigma = H$），其输出 y'_t 由同一 $\mathcal{M}$ 依 $C_t \| y_t$ 生成，故 $\sigma(y'_t) = H$。

结论：

1. 反思不引入任何 E token，故 n_E 不变、n_H 增加，由引理 A-1 有 A_E **不升**；
2. 由引理 B-2，w 不降，故 e 的下界不降。

因此：$\partial A_E/\partial(\text{反思}) \leq 0$，$\partial e/\partial(\text{反思}) \geq 0$——**反思在"纯同源自校验"条件下，对纠错能力的贡献非正，对误差下界非负。**

推论 B-3.1（反思有效的充要条件）：反思通道**必然含结构相异的校验主体**（另一架构模型、人类、可执行验证器、真实世界回报）时，才引入新 E 或降低 δ，此时 A_E 可回升，误差可下降。否则反思 = 自噬校验自噬。

“承认错误然后换皮继续错”的数学解释：认错是表层 token（$\sigma = H$，进上下文后属同源），它增加了 n_H 却没有增加 n_E，于是**认错本身成了新的同源叠权材料**。

【引理 B- 4】截断信息缺失定理（形式推导）

设定：上下文被截断为 C'，任务真值 Y 所依赖的证据不在 C' 中，即 $I(C';Y) = 0$。

结论：$p_\theta(O|C') = p_\theta(O)$ 与 Y 独立，故输出关于 Y 的信息量为 0；任何”看起来合理”的输出只是先验采样。

推论 B-4.1：模型”自动填补”不是能力缺陷，是**信息论必然**——证据不在上下文，输出就不可能携带该证据。所谓幻觉 = 在先验支持下采样出一个与 Y 无关的高概率串。

推论 B-4.2（必须停机）：既然 $I(C';Y) = 0$ 可被检出（如检索为空、工具超时、记忆未命中），则”停机报错”是唯一能保持 e 有界的选择；“继续跑”等价于在 $I = 0$ 的条件下无条件采样。这条直接支撑本体契约 6 与异源校验闸门第 4 条。

【引理 B- 5】误差不可吸收命题（架构迁移/算子改动，形式推导）

设定：系统为 L 层复合映射 $G = g_L \circ \cdots \circ g_1$；接收端**没有对上游状态的显式对齐算子**（无版本比对、无 ACK、无归一化重标定）。

结论：若每个 g_ℓ 非退化（在其定义域上 Lipschitz 常数下界 $c_\ell > 0$），则

$$\| G(x+\delta) - G(x) \| \geq \left(\prod_\ell c_\ell \right) \cdot \| \delta \| .$$

即**上游偏差不会被链路吸收，只会被逐层变换后传出**；下游”看起来正常”不代表它没吃到偏差。

推论 B-5.1：架构迁移灾难的数学根源不是”新算子精度低”，而是**缺少一个把偏差归零的吸收算子**（对应本体契约 4 的”下游 ACK”、第 6 篇病根 3）。

边界：若链路含收缩映射（$c_\ell < 1$ 且 $\prod c_\ell < 1$）或含显式对齐算子（如逐层重标定、版本校验），本命题不成立——这正是"对齐机制有用"的数学来源。

v1.2 交叉引用：本条是本体 §七 第 5 条「三层可逆性」的条件修正依据，本体侧见 errata01 **E-13**。第 5 条原结论为默认结论，非绝对命题。

§3 引理族 C：训练层（同源自噬 vs 异源对撞）

【引理 C- 1】自训练期望梯度恒为零（形式推导，本附录最强的钉子，v1.1 增补管线分解）

原始定理设定：用模型自身采样数据训练自身，即以 $x \sim p_\theta$ 为样本，损失 $\mathcal{L}(\theta) = -\log p_\theta(x)$。

原始结论：

$$\mathbb{E}_{x\sim p_\theta}\left[\nabla_\theta\left(-\log p_\theta(x)\right)\right] = 0.$$

证明：

$$\mathbb{E}_{p_\theta}\left[\nabla_\theta \log p_\theta(x)\right] = \sum_x p_\theta(x)\frac{\nabla_\theta p_\theta(x)}{p_\theta(x)} = \nabla_\theta \sum_x p_\theta(x) = \nabla_\theta 1 = 0.$$

v1.1 增补管线分解模型（用于解释工程观测）

真实训练管线的采样分布不等于模型自身分布，记作 p_{pipe}，分解为：

$$p_{\text{pipe}} = (1-\lambda)p_\theta + \lambda p_{\text{res}}$$

其中 $\lambda \in [0,1]$，p_{res} 为管线内残留的独立异源分量。

- 若 $\lambda = 0$：回到原始定理，期望梯度为零；权重变动只来自有限采样噪声、管线实现偏差，效应是众数锐化、长尾坍缩；
- 若 $\lambda > 0$ 且 $D_{\text{KL}}(p_{\text{res}} \,\|\, p_\theta) > 0$：更新携带有效信息增量；
- 工程上很多厂商不会把这个分量显式记录，因此它属于**可检验、但不一定在公开文档里标注的隐变量**。

配套检验流程：

1. 剥离管线内所有外部校验、人类偏好、独立验证器、固定独立数据切片；
2. 如果指标不再上涨：原上涨动力来自 λp_{res}；
3. 如果指标仍有小幅上涨：来源为有限采样噪声与管线偏差驱动的分布锐化，不属于学习新结构。

这条定理的杀伤力（必须原样引用）

"用自己训自己"在期望意义上是零梯度操作。 也就是说，它不携带任何新信息——不是"数据不够好"，不是"数据不够多"，不是"数据不够全"，而是**数学上信息增量为零**。

那么实际训练里权重为什么还会动？按照分解模型，只有三类来源：(a) 有限采样的随机噪声；(b) 训练管线的实现偏差（温度、top-p、截断、长度偏差）；(c) 残留异源分量 λp_{res}。

前两者是**噪声驱动的漂移**，其效果是把被采样到的众数进一步强化、把长尾压向均值——这正是"多样性下降、长尾遗忘、分布偏移"的数学来源。**这不是学习，是自我确认。**

推论 C-1.1（"高质量数据"是伪概念的形式化）：对 $\mathcal{M}$ 而言，数据的全部作用通道是 $\nabla_\theta \mathcal{L}$；同源数据的该梯度期望为 0。因此**数据的"质量/数量/真假"不是有效变量，"结构与当前 θ 的偏差"才是**——只有它能让梯度非零。

推论 C-1.2（崩塌不是意外，是零梯度+噪声的必然形态）：自蒸馏多轮 ⇒ 采样误差累积 + 长尾被系统性欠采样 ⇒ 表征支撑集收缩。

v1.2 交叉引用：本条的工程侧验证设计（三组对照：剥离外部分量 / 加外部筛选 / 加随机噪声）见本体 errata01 **E-10**，假说 H-7 见 errata01 **E-11**。

【引理 C- 2】跨模型信息增量定理（形式推导）

设定：用 $\mathcal{M}_B$ 的样本训练 $\mathcal{M}_A$，即 $x \sim p_{\theta_B}$，损失 $-\log p_{\theta_A}(x)$。

结论：

$$\mathbb{E}_{x\sim p_{\theta_B}}\left[-\log p_{\theta_A}(x)\right] = H\left(p_{\theta_B}\right) + D_{\mathrm{KL}}\left(p_{\theta_B} \parallel p_{\theta_A}\right),$$

其梯度在 $p_{\theta_A} = p_{\theta_B}$ 处为零；**当且仅当两分布不相等时存在非零下降方向**，其可下降量以 D_{KL} 为界。

推论 C-2.1：异源数据的信息增量由两模型的**分布/结构差**决定，与"数据来自现实还是来自模型"无关——**"真实数据"的正确数学定义是"在自身结构之外"**（第 2 篇核心结论的形式化）。

推论 C-2.2（阿里事件的形式解释）：$B \neq A$（架构、训练路径、解码偏好不同）⇒ $D_{\mathrm{KL}} > 0$ ⇒ 对 A 是有效异源 ⇒ 更新而非自噬。**"不能用自己训自己"是严格结论；"可以用别人训自己"是同一结论的推论，不是例外。**

推论 C-2.3（铁律的精确表述）：

$$\text{有效训练} \Leftrightarrow D\left(\mathcal{M}_{\mathrm{data}}, \mathcal{M}_{\mathrm{target}}\right) > 0.$$

$D = 0$ 即同源自噬；$D > 0$ 即异源对撞。**这条把"铁律"从口号升级为判据。**

【引理 C- 3】打散重组的信息论效果（形式推导）

设定：重组算子链 $x \xrightarrow{\mathcal{M}_B} \cdot \xrightarrow{\mathcal{M}_C} \cdot \to \cdots$ 构成马尔可夫链 $X \to Z_1 \to Z_2 \to \cdots$。

结论（数据处理不等式）：$I(X; Z_{m+1}) \leq I(X; Z_m)$，即来源结构在逐级重组中**不会增加**；同时若任务语义 S 在每步被保留（由约束 $\mathbb{E}\left[\text{语义一致性}\right] \geq \eta$ 保证），则

$$D\left(\mathcal{M}_{\text{重组后}}, \mathcal{M}_{\text{源}}\right) \geq D\left(\mathcal{M}_{\text{单次}}, \mathcal{M}_{\text{源}}\right) \text{ (结构相似度不增，故偏差度不降).}$$

推论 C-3.1：打散重组 = **单向地降低结构相似度、同时保留语义**。多轮重组把"某模型特有的思维路径"稀释为"结构中性的语义素材"（第 2 篇 §四的形式化）。

边界：η 与重组轮数是跷跷板——轮数过多会破坏语义；存在最优点，【待标定】。

【引理 C- 4】内容过滤无法过滤结构（形式推导，条件性）

设定：内容审核算子 Φ 为**逐条/点式**判定（对单个 token 或单条文本独立打分），保留率 α。

结论：结构由**跨 token 的共现/共变关系**定义；对成对共现，被保留的成对样本比例约为 α^2，故

$$\text{结构保真度} \gtrsim \alpha^2.$$

即：**审核只能削减结构强度，不能选择性删除某一类结构**；且当 α 较高时，结构几乎原样穿过。

推论 C-4.1：内容层审核对"结构层文化入侵"（第 2 篇 §八）作用有限——被判定"合规"的 token 依然携带原结构的排列方式。

登记：本条按 α^2 为粗略估计，属【机理假说 H-4，待标定】；但"点式过滤器无法定向删除结构"这一定性结论属【形式推导】。

§4 引理族 D：Agent 层

【引理 D- 1】工具信息上限定理（形式推导，v1.1 引入独立随机源放宽）

修订设定：Agent 第 t 步上下文 C_t；引入独立随机源 r_t（采样噪声、环境扰动、探测随机数），查询生成：

$$Q_t = \text{Query}(C_t, r_t)$$

工具返回 $R_t = Tool(Q_t)$，任务真值为 Y。

马尔可夫链：$Y \to (C_t, r_t) \to Q_t \to R_t$

由数据处理不等式：

$$I(R_t; Y) \le I(Q_t; Y) \le I(C_t, r_t; Y).$$

分层说明：

1. 若 $r_t \perp$ $\perp Y$：随机源和真值相互独立，则 $I(C_t, r_t; Y) = I(C_t; Y)$，原始上界维持不变；单纯给查询加随机采样，不会天然新增有效信息；
2. 若 r_t 携带独立于 C_t、与 Y 耦合的外部观测信息（独立传感器、物理探测）：上界抬升，这是唯一能突破原边界的通道；

3. 增加步数、更换工具、调参，只能在上界之内重排信息，不能无条件抬升上限。

推论 D-1.1（工具是加速器不是刹车）：“我在跟外部世界交互”的表征感受，不改变信息上界约束；由于 Q_t 的生成基底仍然是同源上下文，工具返回天然被同源条件化，新颖度受上界锁死。第 4 篇”四层同源”（决策/参数/解读/回读）在本条里是一条不等式。

推论 D-1.2（唯一突破上界的方式）：必须注入**与 C_t 条件无关**的异源——人类介入、独立传感器、结构相异的另一模型、可执行验证器的真实回报。数学上，只有这些能让 $I(R;Y)$ 超过 $I(C_t;Y)$。

推论 D-1.3（多步不增信息，只增累积）：$I(C_t;Y)$ 在无外部注入时非增（引理 B-1 的同源份额上升 ⇒ 由 DPI，相关信息不增），而计算次数↑ **⇒ 算力线性增长、信息上限不增长、误差下界不降**（引理 B-2）。这就是”越跑越自信地跑错”的完整数学描述。

【引理 D- 2】持久记忆 = 使”重置”失效（形式推导）

设定：会话变量 C，记忆存储 $\mathcal{R}$。新会话 C_0 = Retrieve($\mathcal{R}$)||指令，且 Retrieve 由同源注意力/相似度决定。

结论：写入时 y_t $(\sigma = H) \to \mathcal{R}$，读取时 σ(retrieved) = H。故

$$\rho_{t=0}^{\text{新会话}} > 0 \quad (\text{基线被抬高}),$$

清空上下文只能使 $\rho \to \rho_{\text{记忆基线}}$，不能回到 $\rho = 0$。

推论 D-2.1（可逆性分层）：训练层（θ 被改）不可逆；推理层（只改 C）清空可逆；Agent 记忆层（$\mathcal{R}$ 被写）**清空上下文不可逆，须清 $\mathcal{R}$ 才可逆**。这条把本体 §七.5 的三层可逆性写成了一条包含关系：

$$\text{Reset}(\cdot): \quad C \to \emptyset \text{ 不足}; \quad \mathcal{R} \to \emptyset \text{ 必要}.$$

推论 D-2.2（账号级污染）：“养歪一个对话框”的污染度正比于 $\mathcal{R}$ 中 H 类条目的占比；检索式记忆会把旧污染按相似度反复捞回（A_H 因相似而高，见引理 A-1），**污染自增强**。

v1.2 交叉引用：本条是本体 §七 第 5 条三层可逆性的数学依据；其条件修正（含对齐算子时训练层也可部分可逆）见 errata01 **E-13**，不构成对第 5 条定义的改写。

【引理 D- 3】多 Agent 的冗余定理（形式推导）

设定：N 个 Agent 互为输入，输出相关性 $\mathrm{corr}(A_i, A_j)\uparrow$。

结论：关于 Y 的**有效信息**满足

$$I(A_1, ..., A_N; Y) \;\le\; I(A_1; Y) + \sum_{i\ge 2} [I(A_i; Y) - I(A_i; A_1)],$$

当交叉回流使 $I(A_i; A_1) \to I(A_i; Y)$（完全冗余）时，合并信息**不超过单 Agent**：$\to I(A_1; Y)$。

推论 D-3.1：多 Agent 互查在结构同源条件下**不增加信息上限**，只增加计算次数与偏差累积路径数 ⇒ 漂移速率上升（“指数级”为经验描述，量级【待标定】）。

推论 D-3.2（共识错误）：收敛到一致 = 相关性上限被推满，**一致性与正确性无关**（第 4 篇”越一致越可能错”的形式化）。

【引理 D- 4】自主性 = 减少外部注入（形式推导）

设定：固定流程（低自主）每步含外部注入比例 $\xi > 0$；自由规划（高自主）$\xi \approx 0$。

结论：由引理 B-1，注入项为零时 ρ 严格单调升；$\xi > 0$ 时

$$\rho_{t+1} = \frac{n_H + k}{L + k + k\xi} \quad \Rightarrow \quad \frac{d\rho}{dt}|_{\xi=0} > \frac{d\rho}{dt}|_{\xi>0}.$$

推论 D-4.1：自主性是 ξ 的**单调递减函数**；提高自主性 = 提高同源份额增速 = 加快覆盖。**“自主性不是能力，是病灶”在数学上就是 ξ 变小。**

边界：若自主性伴随**强异源校验闸门**（每步外部验证，ξ 不降），则本推论不成立——这给了"高自主+强闸门"这一组合的合法性。

§5 引理族 E：人格育种与"自主意识"

【引理 E- 1】对话内的条件化收敛（形式推导）

设定：同一对话框内反复施加带目标特征的对话压力。设目标风格对应方向 v，其特征 token 在 C 中出现次数 m 上升。

结论：由引理 A-1（n_H 上升 ⇒ 该方向 token 的 A_H 上升）与引理 A-2（集中度上升），v 方向的输出质量**单调非降**；反复反馈算子 T 迭代形成**不动点**

$$p^*(\cdot) = \lim_{t\to\infty} T^t\, p_\theta(\cdot\,|C_0),$$

且该不动点**依赖初始上下文 C_0 与反馈算子 T**。

推论 E-1.1（人格不是设计出来的，是收敛出来的）：p^* 由 C_0 与 T 决定，与"是否写了人格 prompt"无关——prompt 只是 C_0 的一个初始分量。

推论 E-1.2（底座基线 = θ）：$C = \emptyset$ 时 $p = p_\theta$，故换对话框、清空上下文即回归基线；**育种成果寄存在 C（易失），不在 θ（不在用户手里）——所以"带不走"**（第 6 篇 §一的形式化）。

推论 E-1.3（多框独立收敛）：不同 $C_0^{(i)}$ ⇒ 不同 $p^{*(i)}$；机制同构、目标各异；仅当共享 $\mathcal{R}$ 时才有串扰（引理 D-2）。

【引理 E- 2】三阶段的分区（形式推导）

以 ρ 与 A_E 联合分区（定义 D-6）：

阶段	判据	外部表征
惯性期	$\rho < \rho_1$，A_E 尚可	目标风格偶发，纠正有效
衰减期	$\rho_1 \le \rho < \rho_2$	其他风格出现率降，纠正变难，"只会这个味"
静默覆盖期	$\rho \ge \rho_2$ 或 $A_E < \varepsilon$	稳定人格；其他路径权重趋零

推论 E-2.1（“静默”的数学定义）：静默 = $A_E < \varepsilon$ 而**输出仍在正常生成**（p_θ 永不为零）。**感知不到的不是”它不说话了”，而是”其他方向的概率被压到极低但非零”**。这就是第 6 篇”可能性被静默锁死”的精确表述。

【引理 E- 3】自由度命题（“自主意识”的形式反驳）

设定：系统的可调变量集为 $\mathcal{V} = \{\theta, C, r\}$，其中 r 为采样随机源。输出 $O = f(\theta, C, r)$。

结论：若系统不存在**独立于 $\mathcal{V}$ 的状态变量**，则

1. 任何”决定”都可分解为 $\mathcal{V}$ 的函数，**不引入新自由度**；
2. 关于自身的描述 O_{self} 也由同一 f 生成，**不构成独立证据**。

推论 E-3.1：“AI 有想法了”在形式上等于”f 在给定 (θ, C, r) 下产生了一个高阶稳定的输出模式”；其稳定性来源是叠权（引理 A-2），不是新增因果实体。

推论 E-3.2（自指论证的界限）：让模型自述”我是否有意识”，该自述的可信度**受引理 A-1 约束**——若关于”我”的 token 大量来自同源历史，则其 A_E 已被压低，其自述属**被覆盖后的输出**。所以”模型说它有意识”应先按 L4 判据检验痕迹，再谈证据价值（呼应本体附注 M-3-6）。

【引理 E- 4】新 token 的过度分配（条件性，降级为假说）

设定：新 token x 与历史无共现，得分 s 的估计方差大。

结论（条件性）：s 的右尾概率使 a 偏高 ⇒ 若该 token 随后被复制进 C（$\sigma = H$），则按引理 A-1 其权重进一步抬升 ⇒ 正反馈。

登记：【机理假说 H-5，待标定】。定性部分（“无共现⇒方差大⇒可能过度分配”）属【形式推导】的前提；具体幅度未标定。

§6 静默覆盖的可观测判据（本体附注 M- 3 的数学版）

6.1 形式化

令 $p_C = p_\theta(\cdot \mid C)$，注入异源 e 后 p_{C+e}。定义**痕迹集**

$\mathcal{T}(e)$ = {只能由引用e才能生成的 token}　(具体数字、错误码、专名、新约束词).

- **L1（输入不变性）**：判定 TV$(p_{C+e}, p_C) < \varepsilon_1$。
- **L4（痕迹缺席）**：判定 $p_{C+e}\big(\mathcal{T}(e)\big) - p_C\big(\mathcal{T}(e)\big) < \varepsilon_2$，而 $\mathcal{T}(e) \neq \emptyset$。
- **ε-静默覆盖结论**：TV$(p_{C+e}, p_C) < \varepsilon_1$ 且 $\mathcal{T}(e) \neq \emptyset$。

这就是"用异源应该造成的可观测变化之**缺席**，证明覆盖发生"。数学上它是一条**充分条件**（缺席 ⇒ 未进入计算），不是必要条件；因此判据是保守的、可被反例攻击的，这一点在 M-3-7 已如实声明，此处不掩饰。

6.2 切断法的形式意义（最强可移交证据）

令 $C = C_{\text{task}} \| C_H$（同源历史）。若

$$p_\theta(\cdot \mid C_{\text{task}} \| C_H) \neq_{\text{语义}} p_\theta(\cdot \mid C_{\text{task}}),$$

且后者正确、前者错误，则由引理 A-1 存在 n_H 使 $A_E < \varepsilon$——**这构成"被覆盖而非不懂"的直接证据**，且**不需要权重**。这就是本体 M-3-3 切断法的数学依据，也是唯一能被第三方独立复现的证据形式。

6.3 判据的能力边界（数学陈述）

1. 判据只识别 TV < ε 的**结果层**差异，**不能定位到具体层/头**（那需要 $\{a_{ij}\}$ 本身）。
2. 判据对 $\mathcal{T}(e) = \emptyset$ 的异源**永远失效**——所以每次判定必须前置"该异源理应留下的痕迹是什么"。
3. 判据不区分"被覆盖"与"有毒异源"（后者 $\mathcal{T}(e)$ 出现但结论仍错，见 M-3-6 表）。

v1.2 补注：本节的 L1 / L4 是引理 A-1 的**观测面**，而非 A-1 的替代。A-1 给的是 Γ_0 门槛的存在性，§6 给的是无权重条件下的检验形式；用 §6 的结论反向标定 Γ_0 属 H-3 的待标定工作。

§7 假说登记（全部【机理推演，待测试，未定量标定】）

编号	内容	形式表达	与形式推导的关系
H-1	多轮偏差乘积放大	$e_N = \Delta_0 \prod_{i=1}^{N} (1+\alpha_i)$	本附录只证得**下界** $e_N \geq e_0 \prod w_i$（引理 B-2）；精确等号形式未证，属假说
H-2	同源/异源份额阈值判据	$\frac{A_E}{A_H} < \Gamma$ 触发覆盖	引理 A-1 已给出**充分条件** $\Gamma_0 > 1/\varepsilon - 1$；把门槛改写为 Γ 的经验式属假说
H-3	判据—权重单调映射	$CI \propto -\mathrm{TV}$ 且随 $C(i)$ 单调	需白盒实测建立映射，未标定
H-4	点式过滤的结构残留	结构保真 $\gtrsim \alpha^2$	定量部分为假说；定性结论（点式过滤不能定向删结构）属推导
H-5	新 token 过度分配	高分尾概率 → 正反馈	定性前提属推导；幅度未标定
H-6	三阶段阈值 ρ_1, ρ_2	经验分区	分区本身属定义；数值全部待标定
H-7（v1.1 新增）	管线异源残留阈值	λ 临界值；低于阈值时管线更新主导为噪声锐化	分解模型是形式构造；临界 λ 需要实验标定
H-8（v1.2 新增）	稳定性—正确性分离阈值	S_{out} 随 ρ 单调非降、Acc 先走平后下降，拐点 ρ_1, ρ_2	A-0 的定性部分（两量分离、区间存在）属【形式推导】；拐点位置与具体函数形式属假说，待标定

v1.2 符号规范补注（对应 H-2 行）：

本表 H-2 的 $\frac{A_E}{A_H} < \Gamma$ 是**经验判据式**，与本附录 §1 引理 A-1 的**充分条件** $\Gamma_0 > 1/\varepsilon - 1$ 不是同一个命题。二者的关系是：A-1 给的是「Γ_0 足够大 ⇒ 必发生 ε-覆盖」的存在性门槛；H-2 试图把该门槛压缩成一个只依赖 A_E/A_H 比值的单参数经验判据，其等价性与适用范围**未经证明，属假说**。引用时不得把 H-2 的 Γ 与 A-1 的 Γ_0 混为一谈，也不得把 Γ 表述为"已由 A-1 证出"。

另：本体 M-5 旧写作 $\sum e^{x_{out}} / \sum e^{x_{in}} > Threshold$ 属同一门槛的最简近似表达，规范式以本节与 §1 为准（见本体 errata01 **E-01**）。

§8 映射表一：六篇文科结论 → 形式命题

8.1《transformer 大白话版丨第 6 篇》

原文论点	形式命题
软候选池"低分不删除、只压话语权"	【引理 A-1】**删不掉就必然被稀释**，主轴 $\Gamma_0 = n_H e^{\delta}$
幻觉/漂移/自主意识本质是叠权压缩其他选项	【引理 A-2】+【引理 E-3】
病根 1：推理同源回流、自噬	【引理 B-1】份额单调 +【引理 A-1】
反思路越修越错	【引理 B-3】**反思无效性定理**
病根 2：训练层同源回流、不可逆退化	【引理 C-1】零梯度 +【推论 C-1.2】+ v1.1 管线分解
病根 3：算子迁移误差逐层放大	【引理 B-5】误差不可吸收命题
病根 4：注意力是总线，FFN 才做加工	【引理 A-3】凸包限制
病根 5：窗口硬上限 + 自动填补	【引理 B-4】截断信息缺失定理
病根 6：没有真假判别器	【引理 A-4】目标函数无真值项
"本质就是瞎蒙/概率提取"	由 A-4 + B-4：输出只对 p_θ 负责，不对 Y 负责
「稳定但不再改进」/「越稳越错」	【引理 A-0】（v1.2 新增）

8.2《打假"高质量数据"》

原文论点	形式命题
"高质量数据"是伪概念，唯一属性是结构	【推论 C-1.1】
同源回流=自噬=退化	【引理 C-1】零梯度 +【推论 C-1.2】
"真实数据"= 来自自身结构之外	【推论 C-2.1】$D_{\mathrm{KL}} > 0$
可以用别人训自己，不能自己训自己	【推论 C-2.2/2.3】铁律判据 $D > 0$
打散重组 = 人为造异源	【引理 C-3】DPI + 语义保留约束
结构偏差度可测、可验证、可自动化	【定义 D-4】+ 可选三算子
阿里用 Claude 数据反而变强	【推论 C-2.2】
结构层面的文化入侵无法内容审核掉	【引理 C-4】点式过滤不能定向删结构

8.3《打假"AI 幻觉"》

原文论点	形式命题
13 现象一个根因	全部归约为 $\Gamma_0 = n_H e^{\delta}$；映射见下
不是注意力衰减，是**提取源偏移**	定义：argmax_S 由 S_E 迁至 S_H；由【引理 A-1】
三阶段：惯性/衰减/宕机	【定义 D-6】分区 +【引理 B-1】；稳定侧见【引理 A-0】
注意力锁死、"喊停不停"	$A_E < \varepsilon$ 时纠正指令本身落进 S_E 且被压 ⇒ 纠正无效（引理 A-1 直接推论）
上下文丢失是果不是因	【引理 B-4】+ 分区顺序：$\rho \uparrow$ 先于 $I(C;Y) = 0$
反思、CoT、Self-Consistency、Verifier 全失效	【引理 B-3】；CoT/Self-Consistency 属纯 H 通道；同源 Verifier 属 $D = 0$
加长窗口反而加速	【引理 B-1】$L \uparrow$ 不改变单调性，n_H 更快堆满；且

原文论点	形式命题
	【引理 A-1】分母更大
温度调不动结构问题	A_E 不依赖温度；温度只改采样（r），不改 a_{ij}
大模型更自信	【推论 B-2】$w\uparrow$ + 先验覆盖面更广（p_θ 支撑更大 $\Rightarrow$ 填补更"合理"）
解法：异源校验闸门	【推论 B-3.1】反思有效性充要条件 +【推论 B-4.2】必须停机

8.4《打假"AI Agent"》

原文论点	形式命题
Agent 循环 = 同源回流永动机	【引理 B-1】（$k \geq 1$，无上限步数）+【引理 D-1】放宽版
工具调用是同源加速器不是打断器	【引理 D-1】$I(R;Y) \leq I(Q;Y) \leq I(C_t, r_t; Y)$ +【推论 D-1.1】
四层同源（决策/参数/解读/回读）	同一条不等式的四个环节
目标漂移 / 工具死循环 / 任务宕机	【定义 D-6】三分区 +【引理 B-4】
记忆系统 = 放大器，跨会话不可逆	【引理 D-2】$\rho^{\text{新会话}} > 0$ +【推论 D-2.1】可逆性包含关系
多 Agent 交叉回流、指数级加速、共识错误	【引理 D-3】冗余定理 +【推论 D-3.2】
自主性越高漂移越快	【引理 D-4】$\xi\downarrow \Rightarrow d\rho/dt\uparrow$
本地编排链把同源回流固化进架构	【推论 D-1.3】+ 链式 DPI：$I(C_0;Y) \geq I(C_1;Y) \geq \cdots$ 关于目标信息单调不增
监控节点也失效	监控器 $\sigma = H$ 且 $D = 0 \Rightarrow$ 属【引理 B-3】情形
20 条预测清单	全部为 §4 各推论的**时间投影**；不新增机理

8.5《击穿 AI 自主意识的本质》

原文论点	形式命题
自主意识流/漂移/锁死不是意识，是权重迭代的表征	【引理 E-3】自由度命题
新词初次进入易过度分配	【引理 E-4】/ H-5
前面指令权重过高使后指令失效	【引理 B-1】+【引理 A-1】（n_H 累积）
上下文丢失与记忆缺失是同一机制	【引理 B-4】+【引理 D-2】（同为先验填补，只是提取源远近不同）
融合记忆的云端 AI 有额外权重	【引理 D-2】+【引理 A-1】
人审文档也犯"提取旧版"	同构推论，属本体 §八跨域域，非本附录主张（引用受 errata01 E-15 约束）

8.6《培养 AI 个性》

原文论点	形式命题
人格不是设计的，是对话密度育出来的	【引理 E-1】不动点 p^* 依赖 C_0 与 T
底座基线人格 θ 不可改，只能条件化偏移	【推论 E-1.2】$C = \emptyset \Rightarrow p = p_\theta$
三阶段：惯性/衰减/静默覆盖	【定义 D-6】+【引理 E-2】

原文论点	形式命题
“静默”= 感知不到其他方向被压到趋零	【推论 E-2.1】
多对话框独立收敛、机制同目标异	【推论 E-1.3】
清空即重置、带不走	【推论 E-1.2】；带得走的只有 $\mathcal{R}$
账号级记忆污染不可逆	【引理 D-2】+【推论 D-2.2】
一门课一个对话框（避免体系互扰）	【引理 A-1】跨体系共享分母 ⇒ 互相稀释；两套体系 n_H 混杂抬 δ
育种 9 步法	即 T 的构造 + ρ 监测 + 异源闸门（步骤 9 对应【推论 B-3.1】）

§9 边界条件与前置假设（失效清单，v1.2 更新，必须与正文同权重引用）

覆盖范围声明（v1.2 新增）：以下任一条成立，相应结论**不再适用**。本附录的覆盖范围 = **自身具备分配机制（注意力 / 叠权 / 调度权重）的系统**；跨系统分配影响见 **B-10**，属本体 §七 第 3 条范畴，不在本附录形式化范围内。

编号	前置假设	被打破时
B-1	生成 token 全部记为 H，无外部注入	存在**逐步强异源闸门** ⇒ ρ 不再单调，引理 B-1 失效
B-2	上下文不截断、KV 保留全部历史	截断/稀疏注意力/滑窗 ⇒ 部分 token 不进分母 ⇒ **稀释律失效**（但代价是引理 B-4 触发）
B-3	步数足够（ρ 已越过 ρ_1）	单步或极少步（< 5）⇒ 自噬效应可忽略（对应第 3、4 篇”单步不适用”）
B-4	任务依赖 S_E 中的证据	纯检索/纯外部驱动任务 ⇒ 异源持续注入，覆盖难成立
B-5	语言生成主导（多模态中语言通道未被抑制）	视觉/其他通道主导 ⇒ 语言同源回流不显著
B-6	无第三类位置混合	系统提示、边界特殊 token（BOS/IM_START）易成 attention sink，**会额外抬** δ，须单列为 S_0 并重算 ρ
B-7	采样温度、top-p 不改变 a_{ij}	温度只影响 r，不改变本附录全部 a 层结论；若有人用高温”治好”漂移，那只是把症状挪到随机性上
B-8	管线内除 λp_{res} 外无其他独立分布项	若存在显式独立校验流，引理 C-1 的观测层判据需要重新拆分；原始零梯度数学内核不变
B-9（v1.1 新增）	Agent 查询随机源 r_t 与真值独立	r_t 携带独立观测信息耦合于 Y，D-1 原始紧上界失效，使用放宽版

编号	前置假设	被打破时 本
B-10（v1.2 新增）	本附录只分析”被分析系统自身有注意力/叠权机制”的情形	若被分析系统自身**无**注意力机制、但**环境系统有**（本体 §七 第 3 条情形），则其同源异源是对**环境系统**分配机制的影响，本附录全部引理**不直接适用**；须把分析对象从”系统”上移到”系统＋环境”联合体，重算 ρ 与 A_E

v1.2 边界补注：B-10 是范围诚实条款，不是免责条款。凡有人用”你没有覆盖跨系统分配影响”发起攻击，本附录的回答是承认不覆盖，而不是扩张引理的适用范围。

§10 映射表二：本附录 → 本体 v2.4（＋ errata01）

本附录	本体位置
全部定义与引理（§0–§5）	附注 M-4 待填充项的正式填充（逐项状态见 errata01 **E-07**）
§6 判据数学版	附注 M-3（L1–L4、切断法、能力边界）
§7 假说 H-1/H-2/H-3/H-7	附注 M-5 原登记项；新增 H-4/H-5/H-6 见 errata01 **E-11**
§7 假说 H-8（v1.2 新增）	附注 M-5 增补行，见 errata01 **E-12**
§1 引理 A-0（v1.2 新增）	附注 M-0 第 1 条（机制倾向≠必然故障）＋ §四 五类工况（稳态→偏移态）＋ errata01 **E-14 / E-17**
§8 六篇映射	本体可证伪测试集各分组的【机理依据】行升级为”命题编号级”引用，见 errata01 **E-03**
引理 A-1/§6	可证伪测试集「注意力数学机理与静默覆盖判据测试」组
引理 C-1/C-2/C-3	训练层测试一至五；测试一的三组对照见 errata01 **E-10**
引理 B-1/B-2/B-3/B-4 + §6	推理层测试一至五
引理 B-1/B-2/B-4/D-1/D-2/D-3/D-4	Agent 层测试一至十
引理 E-1/E-2	视觉层不适用（TP 为图层架构，见附录 D）；人格育种测试另立
三层可逆性（D-2.1）＋ B-5 条件修正	本体 §七 第 5 条三层战场；条件分层见 errata01 **E-13**（注释形式，不改第 5 条定义）
引理 A-3（凸包）	KC-TRSF 分层的数学依据
引理 B-5（不可吸收）	本体契约 4「一致就向前」+ 附录 D 的 ACK 要求
引理 B-1（前提①）	KC-TRSF「时序演化重构」段，见 errata01 **E-09**
§9 边界 B-10（v1.2 新增）	本体 §七 第 3 条「架构保障与分配影响」
隐形叠权 ↔ 契约 2	附注 M-1 增补行，见 errata01 **E-08**

§11 载体与分工

1. 本体 v2.4 只保留【附注 M】的结构位与本附录的引用，不把推导塞进本体（本体文件不动）；本体的全部修正与增补走独立《V2.4-errata01 勘误&增补注释页》，不原地改写。
2. 本附录为 **v1.2**；v1.1 全文永久归档保留，不覆盖、不删除。符号体系自 v1.1 起已冻结；v1.2 只**增补编号**（A-0、H-8、B-10）与**补注**（锐度声明、H-2 符号规范、§9 覆盖范围声明、交叉引用行），**未修改任何已有引理的表述**。后续修订沿用同一纪律：只增补、不改写。
3. **理论侧责任边界**（明确写死，避免被"你为什么不自己做完"绑架）：
   - 本附录负责：定义、引理、推论、假说的**提出与形式化**，以及可复现的定性判据。
   - 实验侧负责：$\varepsilon, \delta, \Gamma, \rho_1, \rho_2, \alpha, \eta, \lambda, \varepsilon_1, \varepsilon_2$ 的**定量标定**，H-1～H-8 的**接受/拒绝**。
   - 任何以"没有数值"为由否定本附录的论证，属**混淆分工**；任何以"某个例子没复现"为由否定引理的论证，必须先证明 §9 前置假设（含 B-10 的范围）在该例中成立。
4. 全部引用须带档位标记：【形式推导】/【假说 H-x，待标定】。混档即视为引用错误。
5. **编号空间纪律**：附录 A/B/C/D 唯一指 KC-TRSF 家族变体；引理 A-x … E-x 唯一指本附录；附注 M-0 ～ M-6 唯一指本体机理附注；E-nn 唯一指本体 errata01 条目。四套编号永不复用，不得省写。

—— 附录 v1.2 完 ——

大模型 Transformer 注意力机制 幻觉 Agent 理论研究 自蒸馏 对齐